Detección de fraude en transacciones con tarjeta de crédito

Informe Final – Proyecto Final Integrador

Diplomado en Ciencia de Datos y Análisis Avanzado

Equipo: Grupo 8

Integrantes: Agustin Ivan Scolieri, Carlos Rumbo, Martín Costa D'Addato, Franco Basilio

Fecha: 26/10/2026

1. Resumen ejecutivo

Problema. Un emisor de tarjetas pierde dinero por fraude y, al mismo tiempo, molesta a sus clientes si bloquea compras legítimas. Se busca decidir, en el momento de la autorización, qué transacciones revisar o bloquear. Se trabajó con 1,85 millones de operaciones sintéticas (2019–2020) de las cuales 0,5 % son fraude.

Solución. Un modelo XGBoost que puntúa cada transacción con variables de la operación y del comportamiento previo de la tarjeta (calculado solo con historia pasada). Se eligió con un criterio fijado antes de mirar el test, tras compararlo con regresión logística, Random Forest, una red neuronal (MLP, incorporada después de conocer el test de los otros tres modelos; no altera la selección), una regla de negocio y un baseline sin historial.

Resultados clave (test, 21 jun.–31 dic. 2020; modelo y umbral fijados antes de mirar el test; el test no interviene en la selección ni en el ajuste del umbral).

Indicador	Sin modelo	Regla de negocio	XGBoost
PR-AUC (piso = prevalencia 0,39 %)	–	–	**0,972**
Fraude capturado (% del monto)	0 %	83,3 %	**98,8 %** (1,12 M de 1,13 M USD)
Fraudes detectados (recall)	0 %	62,9 %	**96,6 %**
Precisión (de cada 100 alertas, fraudes)	–	28,5	**75,9**
Falsas alarmas por día	0	17,5	**3,4** (1,2 por 1.000 transacciones; 2,7–4,2 según la semilla)
Ahorro neto en el período (supuesto: 10 USD por falsa alarma)	0	0,91 M USD	**1,11 M USD**

Impacto. Frente a la regla de negocio, el modelo captura 15,5 puntos más del monto de fraude con entre 4,1 y 6,6 veces menos falsas alarmas según la semilla (5,1 con la semilla base); el ahorro neto adicional es de ≈ 0,2 M USD en 6,4 meses (el ahorro neto total del modelo anualizado es de ≈ 2,1 M USD; ver sección 6). **Advertencia:** los datos son sintéticos y sus patrones son muy regulares; estas cifras muestran que el enfoque funciona, **no** el rendimiento esperable en producción. La tasa de fraude cae entre train y test (0,58 % → 0,39 %): el ranking del modelo se mantiene, pero la precisión a umbral fijo cae cuando baja la prevalencia (diciembre: 64 %).

2. Definición del problema y relevancia

Contexto y motivación. En fraude con tarjetas, cada transacción debe aprobarse o frenarse en milisegundos. Perder un fraude cuesta el monto completo; frenar una compra legítima cuesta tiempo de revisión, fricción y riesgo de abandono del cliente. Como solo 4 de cada 1.000 transacciones del test son fraude, un modelo que apruebe todo tendría

99,6 % de exactitud sin detectar nada: por eso se evalúa con PR-AUC, recall, precisión y monto capturado, nunca con exactitud.

Objetivo medible (fijado antes del modelado final). Maximizar el monto de fraude capturado menos el costo de las falsas alarmas, superando a (i) la regla de negocio y (ii) la regresión logística sin historial, con PR-AUC como métrica técnica principal. Metas de referencia a validar con el tutor: recall ≥ 80 % con precisión ≥ 50 % en el holdout temporal.

Costo de cada error.

Situación	Lectura	Costo de negocio
Fraude no detectado	Falso negativo	Monto del fraude (USD)
Compra legítima marcada	Falso positivo	Revisión + fricción: **10 USD (supuesto)**, con sensibilidad 5–50 USD
Aprobar todo	Mayoritaria	99,6 % de exactitud y 0 % de fraude capturado

Hipótesis. H1: el fraude se concentra de noche. H2: se concentra en ciertas categorías de comercio. H3: los montos fraudulentos son mayores. H4: el comportamiento histórico de cada tarjeta aporta señal adicional.

3. Datos y metodología

Fuente. *Credit Card Transactions Fraud Detection* (Kaggle, simulador Sparkov; datos sintéticos). Licencia: CC0 (dominio público).

Archivo	Filas	Fraudes	Tasa	Período
`fraudTrain.csv`	1.296.675	7.506	0,579 %	2019-01-01 → 2020-06-21
`fraudTest.csv`	555.719	2.145	0,386 %	2020-06-21 → 2020-12-31

Se mantiene el corte cronológico original: se entrena con el train y se evalúa en el test. En train: 983 tarjetas, 693 comercios, 14 categorías y 494 ocupaciones; en test: 924 tarjetas, 693 comercios, 14 categorías y 478 ocupaciones.

Calidad y decisiones de limpieza.

Hallazgo	Decisión
0 nulos, 0 duplicados, `trans_num` único	Sin imputación ni eliminación
`amt` muy asimétrica (mediana 47,5; media 70,4; máx. 28.949 USD; 5,2 % sobre el límite IQR)	Los valores altos no son errores: por encima del máximo fraude (1.376 USD) todas las compras son legítimas (48 de las 50 mayores, hasta 28.949 USD, son de `travel`), y el tramo sobre el límite IQR concentra buena parte del fraude, por lo que recortarlo borraría señal: se conservan y se usa `log1p(amt)` (cierra la decisión pendiente log vs. winsorizing)
Alta cardinalidad: `merchant` (693), `job` (494)	Codificación por frecuencia sin etiquetas, ajustada en cada fold solo con su ventana de entrenamiento; para el ajuste final, solo con train
Datos personales / identificadores	Excluidos: `first`, `last`, `street`, `trans_num`, `cc_num`, `unix_time`, `zip`, `city`, `state`, coordenadas crudas (resumidas en `dist_km`)
Fechas como texto; `dob`	`datetime`; edad al momento de la transacción

Conclusiones del EDA (figura 1).

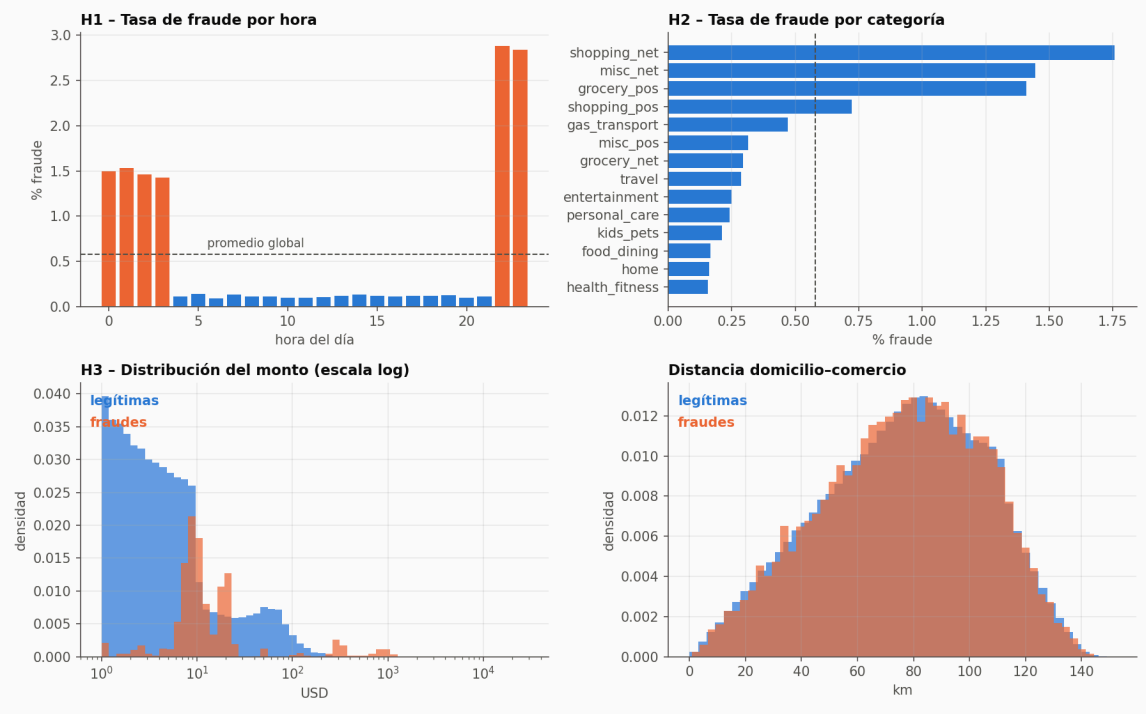


Figura 1. EDA

1. **H1 respaldada:** 22–03 h concentra el 84,8 % de los fraudes con el 23,5 % de las transacciones; tasa 2,09 % de noche vs. 0,12 % el resto del día.
2. **H2 respaldada:** `shopping_net` (1,76 %), `misc_net` (1,45 %) y `grocery_pos` (1,41 %) superan entre 2,4 y 3 veces el promedio global (0,58 %).
3. **H3 respaldada con matiz:** monto medio 531 USD en fraude vs. 68 USD (mediana 397 vs. 47), pero la distribución es **bimodal**: hay fraudes de monto chico (hasta ≈ 50 USD) y de ≥ 200 USD, y casi no hay entre 50 y 200 USD (tasa < 0,1 %). Desde 200

USD la tasa supera 2,5 % y por encima de 1.000 USD ronda 24 %. Es un patrón muy regular, típico del simulador.

4. La **distancia** domicilio–comercio no discrimina por sí sola (distribuciones prácticamente idénticas entre clases).

Drift entre train y test (figura 2; devolución del tutor).

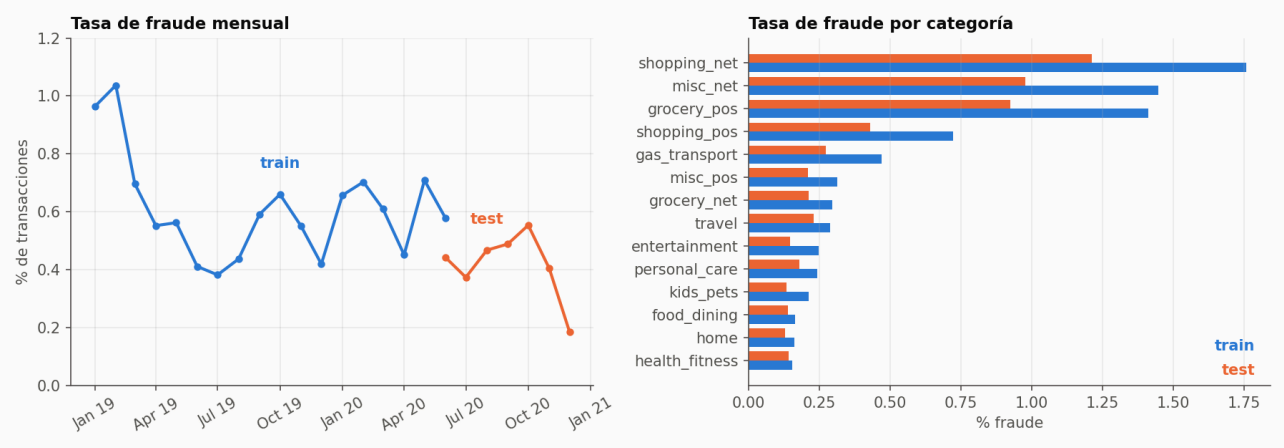


Figura 2. Drift

La tasa baja de 0,58 % a 0,39 %. Si cada categoría mantuviera su tasa de train sobre la mezcla de test, la tasa esperada sería 0,578 %: **el cambio no se explica por la composición de categorías**, sino por menor fraude dentro de cada categoría. Las distribuciones de las variables son estables (PSI < 0,01 en monto, distancia, hora, edad, población y categoría). Lectura: cambio de régimen de la tasa, no de la mezcla de comercios; el impacto sobre el modelo se mide en la sección 4.

Ingeniería de variables sin fuga (devolución del tutor). Se calcularon por tarjeta, **solo con transacciones anteriores** a la evaluada: cantidad de transacciones previas, tiempo desde la anterior, media y desvío pasados del monto, razón y z-score del monto actual contra su historia, cantidad y suma de las últimas 1 h y 24 h, y si la categoría es nueva para la tarjeta; más hora, día, franja nocturna, edad, `log1p(amt)`, distancia haversine, población, género y categoría. No se usan etiquetas pasadas. Para las primeras transacciones del test se usa el historial real de la tarjeta en el train (pasado, no futuro).

Verificación: calculadas con los datos truncados al 2019-09-01, las 11 variables históricas resultan **idénticas** a las calculadas con todos los datos, mientras que una variable "con futuro" (media por tarjeta de todo el período) sí cambia (`results/verificacion_sin_fuga.csv`).

Metodología. Se siguió CRISP-DM: negocio (sección 2), datos (sección 3), preparación (sección 3), modelado y evaluación (sección 4), y despliegue como recomendación (sec-

ción 7). Todo el proceso es reproducible (`SEED = 42`, notebook ejecutable de principio a fin en ≈ 12 min) y las decisiones están en `data_log.md`.

Diseño de validación	Qué responde
CV temporal de 4 ventanas expansivas dentro de train, con el desbalance tratado dentro de cada fold	¿Qué modelo discrimina mejor? Define el modelo y el umbral
Holdout temporal (train → test); modelo y umbral fijados antes, sin retoques posteriores. Los diagnósticos (semillas, ablaciones, mes a mes, sensibilidad) reutilizan el mismo test y no intervienen en la selección	¿Generaliza hacia adelante, con drift incluido?
Test mes a mes	¿Se mantiene el desempeño cuando cambia la prevalencia?

4. Modelado y evaluación

Algoritmos y regla de selección. Se compararon regresión logística (referencia interpretable, pesos de clase), Random Forest, XGBoost (`scale_pos_weight`) y una red neuronal MLP de dos capas (64 y 32 neuronas; sin `class_weight`, por lo que recibe pesos por muestra con una razón de clases calculada dentro de cada fold, análoga a la usada por los otros modelos, y sin *early stopping*, que reservaría una parte al azar del train y rompería el orden temporal; convergió en las 12 ejecuciones de CV, entre 60 y 130 iteraciones, antes del tope de 300). XGBoost y el MLP son estocásticos: en CV se entrenan con 3 semillas y se promedian, más tres baselines: clasificador mayoritario, regla de negocio (noche y monto > 240 USD, ajustada solo con train) y regresión logística sin variables históricas (equivalente a la pre-entrega). **Regla de selección:** mayor PR-AUC medio en CV temporal; los modelos a menos de un desvío del mejor se consideran empatados y gana el más simple (logística < Random Forest < XGBoost < MLP). **Nota metodológica:** el criterio se definió antes de evaluar en test; el conjunto de candidatos se amplió con el MLP después de las primeras corridas. Como el MLP queda por debajo del umbral de empate, la selección no depende de ese agregado.

Selección (CV temporal, media ± desvío entre folds; XGBoost y MLP: promedio de 3 semillas).

Modelo	PR-AUC	ROC-AUC	Recall al revisar 0,5 % de las transacciones
XGBoost	**0,972 ± 0,015**	0,999	88,4 %
Red neuronal (MLP)	0,935 ± 0,046	0,997	84,6 %
Random Forest	0,903 ± 0,050	0,997	80,4 %
Logística	0,362 ± 0,046	0,982	47,0 %
Logística sin historial (baseline)	0,237 ± 0,027	0,968	34,1 %

El umbral de empate es 0,957: solo XGBoost lo supera (el MLP queda segundo, 0,935), por lo que **no hay empate** y XGBoost queda seleccionado.

Evaluación en test, umbral por costo (10 USD por falsa alarma).

Modelo	PR-AUC	Recall	Precisión	F1	Fraude capturado	Falsas alarmas totales (por día)
Mayoritaria	0,004 (piso)	0 %	–	–	0 %	0
Regla de negocio	–	62,9 %	28,5 %	0,39	83,3 %	3.378 (17,5)
Logística sin historial	0,184	69,3 %	15,8 %	0,26	94,7 %	7.952 (41,1)
Logística	0,285	78,0 %	27,3 %	0,40	94,2 %	4.452 (23,0)
Random Forest	0,915	92,9 %	55,7 %	0,70	98,3 %	1.587 (8,2)
Red neuronal (MLP)	0,947	95,4 %	59,7 %	0,73	98,2 %	1.384 (7,2)
XGBoost	**0,972**	**96,6 %**	**75,9 %**	**0,85**	**98,8 %**	**657 (3,4)**

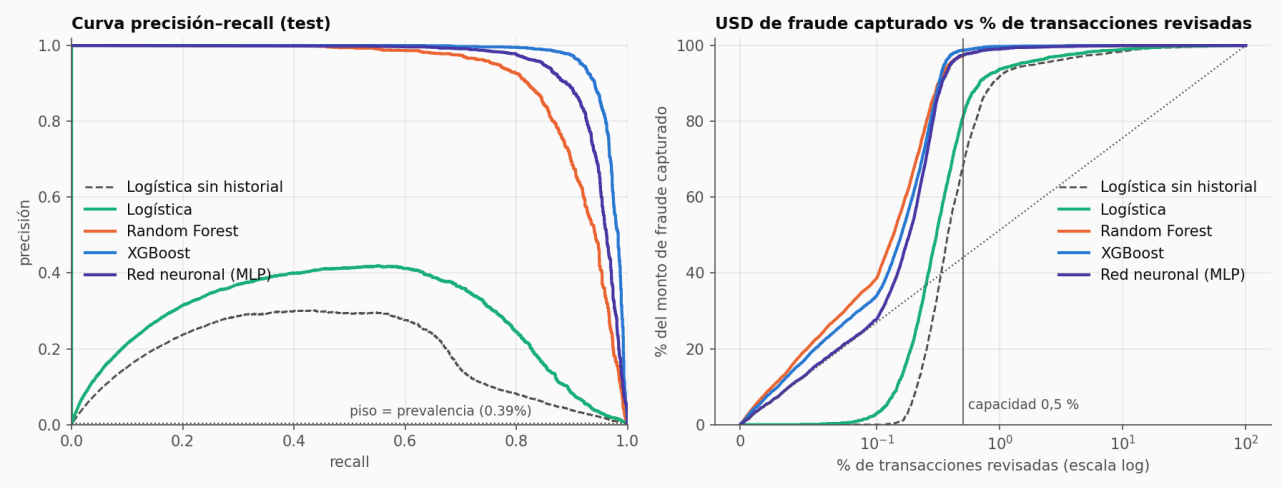


Figura 3. Curva PR y curva de ganancia (test)

Lectura. (i) XGBoost supera con holgura a la regla y a la regresión logística y queda por delante de Random Forest y del MLP en PR-AUC (0,972 vs. 0,915 y 0,947) y en ahorro neto; frente al MLP también tiene mayor recall y precisión en las 3 semillas, aunque el punto operativo exacto cambia con la semilla (ver robustez más abajo). De 2.145 fraudes detecta 2.072 y deja pasar 73 (matriz de confusión en el anexo C). (ii) La regresión logística, que no captura interacciones (monto × hora × categoría), queda lejos: el valor está en los modelos no lineales (árboles y red neuronal). (iii) Como punto operativo alternativo, revisando solo el 0,5 % de las transacciones con mayor score, XGBoost captura 96,6 % de los fraudes y 98,8 % del monto con 706 falsas alarmas. (iv) El umbral (0,102) se eligió sobre predicciones fuera de muestra del último fold de CV, nunca sobre el test.

Robustez a la semilla (diagnóstico; no se usa para seleccionar). XGBoost y el MLP se reentrenaron con 3 semillas, cada una con su propio umbral por costo:

Modelo	PR-AUC (test)	Recall	Precisión	Falsas alarmas	Ahorro neto (USD)
XGBoost	0,972–0,975	96,4 %–96,7 %	71,6 %–80,1 %	515–822	1,113 M–1,114 M
Red neuronal (MLP)	0,947–0,951	93,6 %–95,4 %	59,7 %–73,0 %	741–1.384	1,095 M–1,100 M

El orden por PR-AUC y por ahorro neto se mantiene en las 3 semillas (XGBoost gana el ahorro neto en cada una) y la diferencia de PR-AUC (≈ 0,025) es mayor que la variación entre semillas (≈ 0,002–0,003). En cambio, el **punto operativo es sensible a la semilla**: la precisión de XGBoost va de ≈ 72 % a ≈ 80 % y las falsas alarmas de 2,7 a 4,2 por día, aunque su ahorro neto varía ≈ 0,1 %. Por eso las cifras de precisión y falsas alarmas deben leerse como órdenes de magnitud; aun así, comparando semilla a semilla, XGBoost supera al MLP en recall y precisión en las 3 (en precisión, por poco en una de ellas: 71,6 % vs. 71,1 %). Las decisiones se apoyan en PR-AUC y ahorro neto.

Impacto del drift en el desempeño (figura 4). Mes a mes, el recall con umbral fijo se mantiene entre 95,3 % y 98,3 % y la PR-AUC entre 0,96 y 0,98: **el ranking no se degrada**. Lo que sí cambia es la precisión: de 71,5–80,7 % (jun.–nov.) baja a **64,4 % en diciembre**, cuando la prevalencia cae a 0,18 % y el volumen de transacciones casi se duplica. Es el efecto esperable: con menos fraude, el mismo número de falsas alarmas pesa más sobre las alertas.

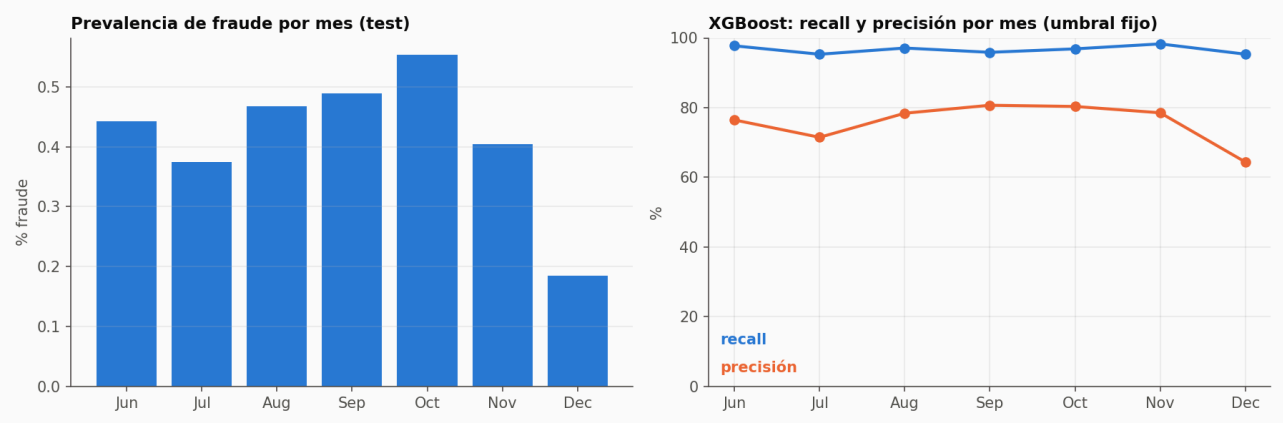


Figura 4. Desempeño mensual en test

5. Interpretación del modelo

SHAP sobre una muestra estratificada del test (500 fraudes + 1.500 legítimas). Las variables más influyentes son el **monto** (`amt`), la **suma gastada en las últimas 24 h** (`log_sum_24h`), la **franja nocturna**, la cantidad de transacciones previas de la tarjeta, `log_amt` (otra forma del monto) y la frecuencia de compras en 24 h (figura 5). En el caso local de

mayor score, un monto de 1.114 USD, un gasto de ≈ 4.700 USD en 24 h y un monto superior a la media histórica de la tarjeta (671 USD) empujan al modelo hacia "fraude".

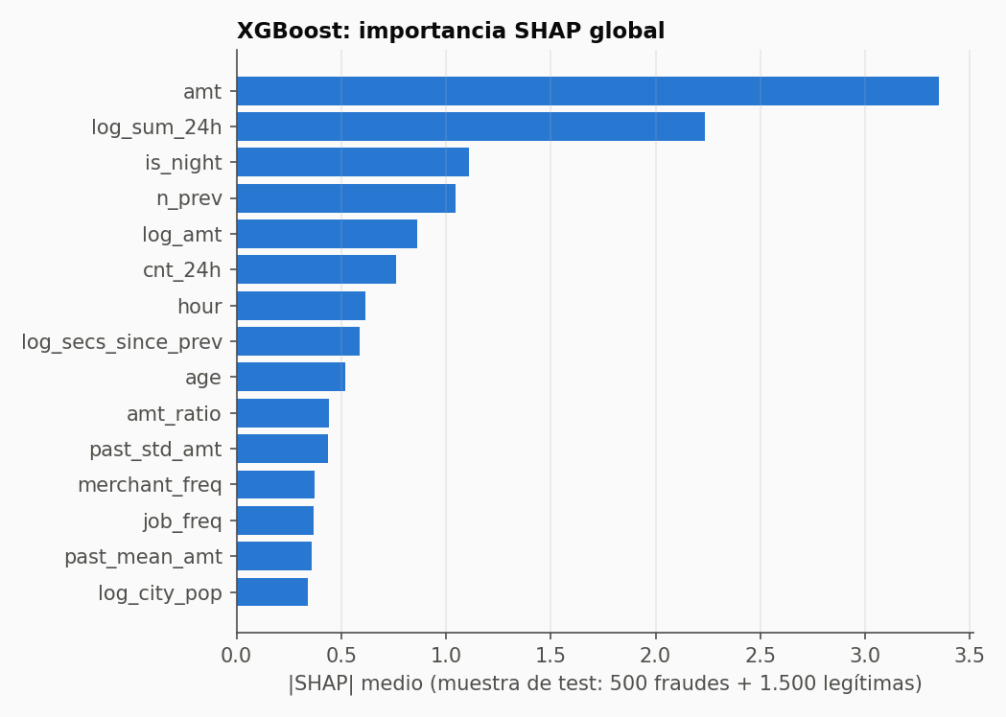


Figura 5. Importancia SHAP global

Ablaciones (se reentrena XGBoost sin cada bloque y se evalúa en el mismo test).

Escenario	PR-AUC	Δ PR-AUC	Recall al revisar 0,5 %	Veredicto
Modelo completo	0,972	–	96,6 %	Referencia
Sin historial por tarjeta	0,865	−0,108	83,2 %	**H4 respaldada**: aporte claro
Sin variables temporales	0,933	−0,040	91,7 %	**H1 respaldada**
Sin categoría ni comercio	0,878	−0,094	85,8 %	**H2 respaldada**
Sin monto actual (y derivados)	0,733	−0,239	72,8 %	**H3 respaldada**: mayor caída
Sin distancia	0,974	+0,002	97,0 %	Sin aporte
Sin `n_prev` (antigüedad de la tarjeta)	0,974	+0,002	96,8 %	El modelo no depende de una variable que crece con el tiempo (ablación agregada después de ver SHAP; descriptiva, no interviene en la selección)

Cada bloque ligado a una hipótesis (H1–H4) aporta, y ninguno por sí solo explica el resultado; distancia y `n_prev` no aportan. `n_prev` aparece entre las variables más influyentes en SHAP, pero quitarla no empeora el modelo: su información es redundante con el resto del historial por tarjeta. SHAP y las ablaciones describen cómo razona el modelo; **no demuestran causalidad**. Que el monto sea lo más importante es consistente con el EDA,

pero el patrón bimodal del simulador probablemente facilita la tarea más de lo que ocurriría con fraude real (sección 6).

6. Impacto en el negocio, riesgos y ética

Valor económico (test, 193 días; supuestos: el fraude marcado se bloquea en tiempo real y evita su monto íntegro; 10 USD por falsa alarma; anualización proporcional, sin crecimiento).

Escenario	Fraude evitado (USD)	Fraude residual (USD)	Falsas alarmas	Ahorro neto (USD)
Sin modelo	0	1.133.325	0	0
Regla de negocio	944.039	189.286	3.378	910.259
Logística	1.067.076	66.249	4.452	1.022.556
Random Forest	1.113.627	19.697	1.587	1.097.757
Red neuronal (MLP)	1.113.364	19.960	1.384	1.099.524
XGBoost	**1.119.266**	**14.059**	**657**	**1.112.696** (≈ 2,10 M anualizado)

Sensibilidad al costo de la falsa alarma (umbral re-optimizado en cada caso): el ahorro neto de XGBoost es 1,116 M (5 USD), 1,113 M (10), 1,103 M (25) y 1,095 M (50), siempre por encima de la regla (0,93 → 0,80 M) y entre 0,9 % y 4,2 % por encima del MLP (semilla base). La conclusión no depende del costo supuesto.

Riesgos y limitaciones.

Riesgo	Mitigación / estado
Datos sintéticos con patrones muy regulares (fraude bimodal en monto, franja nocturna rígida): PR-AUC ≈ 0,97 es un techo poco realista	No extrapolar; en producción esperar menos. Piloto en sombra y reentrenamiento con datos reales antes de decidir
Drift de la tasa de fraude (0,58 % → 0,39 %)	Monitorear prevalencia, precisión y distribución del score; umbral por capacidad de revisión además del umbral por costo; reentrenar periódicamente
Fuga de información temporal	Variables solo con pasado, verificadas con prueba automática
Costo de falsa alarma desconocido	Análisis de sensibilidad 5–50 USD
Adaptación del fraude al modelo	Reentrenamiento y revisión de variables; los atacantes cambian de patrón
Umbral por costo sensible a la semilla y a la versión de las librerías (XGBoost: precisión 72–80 %, 2,7–4,2 falsas alarmas por día)	Reportar rangos; umbral por capacidad de revisión; versiones fijadas en `requirements.txt`; recalibrar el umbral periódicamente
Umbral calculado con una versión del modelo y aplicado a otra	Se compara con un punto operativo por capacidad (0,5 %) que no depende de la escala del score

Ética y privacidad. Los datos son sintéticos y no contienen personas reales. Aun así se aplicaron las prácticas que correspondería en un caso real: se excluyeron nombre, apellido, calle, identificador de transacción y número de tarjeta de las variables del modelo, y se trabajó con ubicaciones resumidas en una distancia. **Auditoría por grupos (test, umbral por costo):** la tasa de alertas es pareja (0,46–0,54 % de las transacciones en todos los grupos) y la tasa de falsos positivos varía poco (género: F 0,13 %, M 0,10 %; edad: 0,08–0,13 %); el recall va de 94,9 % a 99,4 % según el grupo, con el menor valor en 45–59 años (94,9 %) y en mujeres (95,2 %). Género y edad son variables del modelo; en un caso real convendría evaluar si hace falta excluirlas y monitorear estas métricas de forma continua, además de contar con revisión humana y vía de reclamo para el cliente bloqueado.

Escalabilidad. El pipeline completo se entrena y evalúa en ≈ 12 minutos sobre 1,85 M de filas (incluye 3 semillas para los modelos estocásticos); las variables por tarjeta requieren mantener un estado por tarjeta (último movimiento, acumulados y ventanas de 1 h y 24 h), compatible con una puesta en producción en tiempo casi real. Queda fuera del alcance de este trabajo.

7. Conclusiones y recomendaciones

- El problema se planteó como priorización de revisiones bajo costos asimétricos, por lo que se evaluó con PR-AUC, monto capturado y falsas alarmas, no con exactitud.
- XGBoost, seleccionado con un criterio fijado antes de ver el test (el MLP se sumó como candidato después, sin cambiar el resultado), captura el **98,8 % del monto de fraude** y el 96,6 % de los fraudes con **3,4 falsas alarmas por día** (precisión 75,9 %; 72–80 % y 2,7–4,2 falsas alarmas según la semilla), frente a 83,3 % y 17,5 falsas alarmas de la regla de negocio.
- El historial por tarjeta, calculado sin fuga y verificado, aporta de forma clara (H4); también lo hacen la hora, la categoría y el monto (H1–H3).
- La caída de la tasa de fraude entre train y test no se explica por la mezcla de comercios; el ranking del modelo se sostiene, pero la precisión a umbral fijo baja cuando la prevalencia cae (64 % en diciembre).
- **Cautela principal:** los datos son sintéticos y sus patrones son muy regulares; los valores absolutos no son esperables en producción.

Recomendación. No desplegar directamente. Próximos pasos: (1) validar con datos reales del emisor en modo sombra; (2) acordar con el negocio el costo de la falsa alarma y la capacidad de revisión; (3) fijar monitoreo de prevalencia, precisión y distribución del score con reentrenamiento periódico; (4) evaluar la exclusión de género y edad y auditar equidad de forma continua.

Anexos

Anexo A. Trazabilidad

Devolución del tutor sobre la pre-entrega.

Observación	Dónde se atendió
Cuidado con las variables históricas por tarjeta: solo transacciones anteriores	Sección 3 (ingeniería de variables y verificación anti-fuga); `results/verificacion_sin_fuga.csv`
Mantener PR-AUC como métrica principal	Secciones 1 y 4 (PR-AUC primero en todas las tablas, con el piso de la prevalencia)
Mostrar dinero de fraude capturado y falsas alarmas	Secciones 1, 4 y 6 (USD capturado, falsas alarmas por día y por 1.000 transacciones, ahorro neto)
Revisar el drift de la tasa train/test	Sección 3 (descomposición y PSI) y sección 4 (desempeño mensual)

Decisiones pendientes de la pre-entrega, ahora cerradas. `amt` extremo → `log1p`, sin winsorizing (compras legítimas); `merchant`/`job` → codificación por frecuencia con train; transacción de 28.949 USD revisada (legítima, `travel`); campos personales excluidos.

Criterios de evaluación de la consigna.

Peso	Criterio	Evidencia
20 %	Problema y alineación con negocio	Secciones 1–2
20 %	Datos, metodología y justificación técnica	Sección 3, `data_log.md`
15 %	Selección y defensa del modelo	Sección 4 (criterio fijado antes del test; CV temporal; test; robustez a la semilla; nota metodológica sobre el MLP)
15 %	Calidad de las métricas	PR-AUC con piso, recall, precisión, F1, USD capturado, falsas alarmas
15 %	Interpretación y valor	Secciones 5–6
5 %	Ética y privacidad	Sección 6
10 %	Impacto y claridad	Resumen ejecutivo, figuras, recomendación

Anexo B. Variables del modelo (36)

Transacción: `amt`, `log_amt`, `hour`, `dow`, `is_night`, `dist_km`, `category` (14 columnas one-hot), `merchant_freq`. Titular: `age`, `gender_M`, `log_city_pop`, `job_freq`. Historia de la tarjeta (solo pasado): `n_prev`, `log_secs_since_prev`, `past_mean_amt`, `past_std_amt`, `amt_ratio`, `amt_z`, `cnt_1h`, `log_sum_1h`, `cnt_24h`, `log_sum_24h`, `new_cat`.

Anexo C. Matriz de confusión de XGBoost en test (umbral por costo)

	Pred. legítima	Pred. fraude
Real legítima	552.917	657
Real fraude	73	2.072

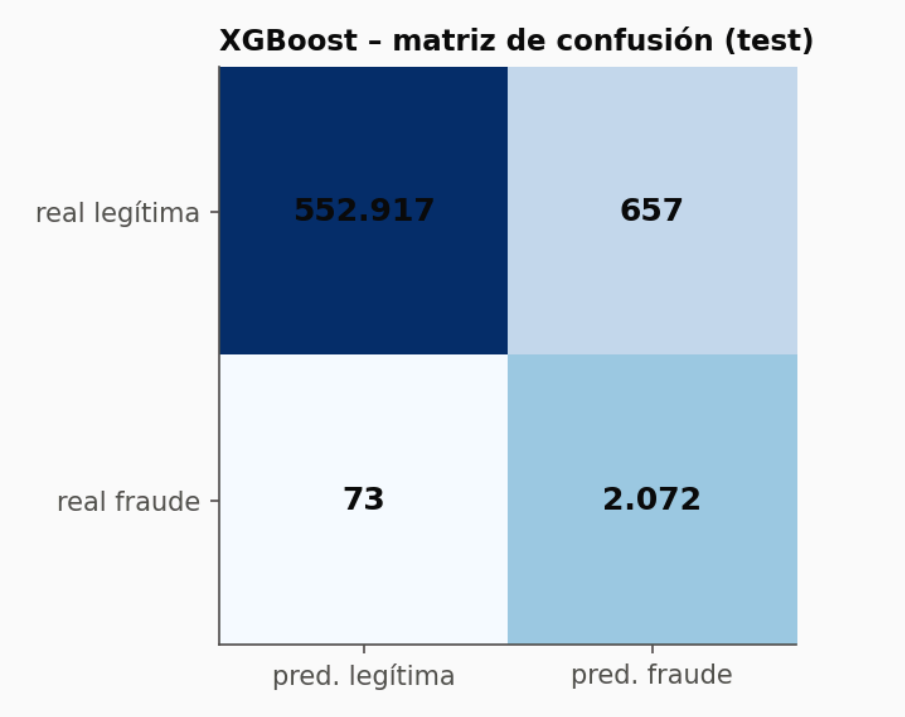


Figura 6. Matriz de confusión

Anexo D. Reproducibilidad y fuentes

Repositorio: https://github.com/utn-diplomatura-cd-2026-grupo-8/proyecto-final. Contiene `deteccion_fraude.ipynb` (ejecutado de punta a punta), `requirements.txt`, `data_log.md`, `README.md` con instrucciones y la carpeta `results/` con todas las tablas y figuras. Dataset: Kartik Shenoy, *Credit Card Transactions Fraud Detection Dataset*, Kaggle, https://www.kaggle.com/datasets/kartik2112/fraud-detection (licencia CC0: Public Domain). Generado con *Sparkov Data Generation* de Brandon Harris, https://github.com/namebrandon/Sparkov_Data_Generation (licencia MIT).

Chapman, P. et al. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS. · Lundberg, S. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. *NeurIPS 30*.